AI Trợ Lý Tri Thức Nội Bộ

Enterprise Readiness Review - Tổng Kết Phase 1

Tối ưu hóa tra cứu tài liệu và quy trình chuẩn bằng AI

Tổng Quan Dự Án

- **Bài toán thực tế:** Nhân sự lãng phí nhiều giờ đồng hồ để tìm kiếm thủ công các chính sách, quy trình (SOP) nằm rải rác trên nhiều hệ thống lưu trữ khác nhau.
- **Người dùng mục tiêu:** Nhân viên toàn công ty, đặc biệt tập trung vào các khối Vận hành, Hành chính, Nhân sự và IT Support.
- **Dữ liệu lõi:** Tài liệu vận hành nội bộ, chính sách bảo mật, sổ tay nhân viên và các biểu mẫu quy chuẩn.

Ràng Buộc Enterprise

Bảo Mật Tuyệt Đối

Tài liệu nội bộ là tài sản công ty. Tuyệt đối không cho phép rò rỉ dữ liệu ra Public Cloud. Không sử dụng dữ liệu doanh nghiệp để huấn luyện mô hình của bên thứ ba.

Phân Quyền & Audit

Hệ thống nhận diện người dùng để trả lời đúng phạm vi tài liệu được phép truy cập. Mọi truy vấn đều phải được lưu trữ Audit Trail (nhật ký) để truy vết khi cần thiết.

Zero Hallucination

Chất lượng và độ chính xác là yếu tố sống còn. Bất kỳ sự sai lệch nào (ảo giác) do AI tạo ra trong quy trình SOP đều có thể dẫn đến rủi ro pháp lý và vận hành lớn.

Kiến Trúc Triển Khai

Hạ Tầng Nội Bộ (On-Premise)

Đảm bảo đóng kín dữ liệu doanh nghiệp.

Toàn bộ Backend xử lý nghiệp vụ, PostgreSQL và đặc biệt là **Vector Database** (chứa tài liệu đã được vector hóa) sẽ được đặt hoàn toàn trên cụm máy chủ nội bộ của công ty.

Đám Mây Bảo Mật (Cloud LLM)

Tận dụng năng lực suy luận mạnh mẽ.

Kết nối với các Cloud LLM hàng đầu thông qua VPC/Private Link có cam kết hợp đồng Enterprise **Zero Data Retention** (Provider không được lưu trữ hoặc học từ prompt).

Phân Tích Chi Phí

Lớp Chi Phí	Giai Đoạn MVP (Test Nội Bộ)	Giai Đoạn Growth (Scale x10 User)
Token API (LLM)	Rất thấp (Vài USD/tháng do ít user).	**Tăng vọt cấp số nhân.** Là chi phí chiếm tỷ trọng lớn nhất do context tài liệu dài.
Compute & Storage	Cố định (1 server nhỏ cho Vector DB).	Tăng tuyến tính (Cần scale server lưu trữ khi tài liệu lớn dần).
Hidden Costs (Chi Phí Ẩn)	Chưa đáng kể.	**Rất Lớn:** Chi phí lưu trữ log Audit bảo mật và bảo trì Data pipeline RAG.

Chiến Lược Tối Ưu

Semantic Caching (Bộ đệm ngữ nghĩa)

Thiết lập hệ thống Cache để tự động ghi nhớ và trả lời các câu hỏi thường gặp (VD: Quy trình xin nghỉ phép). Chiến lược này giúp giảm ngay lập tức 30-40% chi phí gọi API LLM.

Model Routing (Định tuyến thông minh)

Sử dụng một mô hình nhỏ gọn, chi phí thấp (hoặc tự host) để phân loại ý định (Intent) của câu hỏi. Chỉ những truy vấn phức tạp mới được định tuyến lên các mô hình đắt tiền như GPT-4o.

Prompt Compression (Nén ngữ cảnh)

Nâng cấp kỹ thuật tiền xử lý RAG. Hệ thống sẽ tự động lọc bỏ các thông tin nhiễu, chỉ trích xuất những đoạn văn bản thật sự chứa câu trả lời trước khi ghép vào prompt, giảm lãng phí token.

Đảm Bảo Độ Tin Cậy

Rủi Ro Sập API (Timeout)

Tình huống: Cloud LLM Provider gặp sự cố gián đoạn dịch vụ diện rộng.

Giải pháp Fallback: Hệ thống tự động chuyển đổi sang Provider phụ (VD: OpenAI lỗi → Anthropic). Nếu cả hai đều lỗi, trả về luồng Rule-based thông báo: "AI đang bảo trì, vui lòng tra cứu trực tiếp tại link...".

Lưu Lượng Đột Biến (Traffic Spike)

Tình huống: Hàng ngàn nhân sự truy cập AI cùng lúc vào kỳ đánh giá cuối năm.

Giải pháp Scale: Đưa toàn bộ các truy vấn vào hệ thống hàng đợi (Message Queue) để xử lý bất đồng bộ (Async), bảo vệ máy chủ nội bộ khỏi nguy cơ sập hệ thống (Crash).

Định Hướng Phase 2

Track Đề Xuất:

AI Engineering & Application

Dự án hiện tại đã xây dựng được Use-case rõ ràng và kiến trúc hệ thống an toàn ở cấp độ Enterprise.

Trong Phase 2, nhóm sẽ tiến sâu vào kỹ thuật **Evaluation Framework** để đo lường độ chính xác (triệt tiêu ảo giác) và phát triển các luồng **Multi-Agent** phối hợp phức tạp nhằm xử lý toàn bộ quy trình hành chính tự động.

Image Sources

https://kelleycreate.com/wp-content/uploads/featured-it-onboarding-checklist-new-employee-1400×547.jpg

Source: kelleycreate.com

---

https://static.vecteezy.com/system/resources/thumbnails/077/819/986/large/3d-render-abstract-blue-neural-network-digital-data-connection-background-high-tech-glowing-nodes-lines-representing-artificial-intelligence-machine-learning-ideal-futuristic-backdrop-video.jpg

Source: www.vecteezy.com